

✓ Analisis_CO2_sin_valores_de_influencia

```
#importar librerias
import pandas as pd
import numpy as np
```

✓ Leer data

```
# pd.read_excel BASE CON VALORES SIN INFLUENCIA.xlsx
```

```
df = pd.read_excel('BASE CON VALORES SIN INFLUENCIA.xlsx')
```

```
df.columns
```

```
Index(['Emission_CO2', 'Anio_emision', 'Dias_hasta_expiracion', 'coord_y',
      'Clasificacion_Emissiones_ordinal', 'Estado_edificio_ObraTerminada',
      'Estado_edificio_ProyectoNueva', 'Tipo_edificio_Bloquecompleto',
      'Tipo_edificio_Edificiocompleto', 'Tipo_edificio_Local',
      'Tipo_edificio_Unifamiliar', 'Muy_antiguo', 'AJUSTES', 'ID',
      'LogEmissiones', 'RES_1', 'DRE_1', 'ZRE_1', 'SRE_1', 'SDR_1', 'MAH_1',
      'COO_1', 'LEV_1', 'DFF_1', 'DFB0_1', 'DFB1_1', 'DFB2_1', 'DFB3_1',
      'DFB4_1', 'DFB5_1', 'DFB6_1', 'DFB7_1', 'DFB8_1', 'DFB9_1', 'DFB10_1',
      'DFB11_1', 'apalancamiento_alto', 'DFFITS_influyente', 'COVRATIO',
      'COVRATIO_influyente', 'algun_dfbetas_influyente',
      'influencia_conjunta', 'influencia_total_suma', 'RES_2', 'DRE_2',
      'ZRE_2', 'SRE_2', 'SDR_2', 'MAH_2', 'COO_2', 'LEV_2', 'DFF_2', 'DFB0_2',
      'DFB1_2', 'DFB2_2', 'DFB3_2', 'DFB4_2', 'DFB5_2', 'DFB6_2', 'DFB7_2',
      'DFB8_2', 'DFB9_2', 'DFB10_2', 'DFB11_2'],
      dtype='object')
```

```
# Filtrar solo las columnas necesarias después de la selección de variables
```

```
df_1 = df[['LogEmissiones', 'Clasificacion_Emissiones_ordinal', 'Tipo_edificio_Local', 'Tipo_edificio_Unifamiliar',
          'Tipo_edificio_Edificiocompleto', 'coord_y', 'Tipo_edificio_Bloquecompleto',
          'Estado_edificio_ProyectoNueva', 'Estado_edificio_ObraTerminada',
          'Dias_hasta_expiracion', 'Anio_emision', 'Muy_antiguo']]
```

```
df_1 #Nombre del dataframe a tratar
```

```

LogEmissiones  Clasificacion_Emissiones_ordinal  Tipo_edificio_Local  Tipo_edificio_Unifamiliar  Tipo_edificio_Edificiocompleto
0              3.404857                      5                      0                      0
1              3.829945                      5                      0                      0
2              3.010621                      4                      0                      0
3              3.668932                      5                      0                      0
4              4.641984                      7                      0                      0
...              ...                      ...                      ...                      ...
164906          4.038656                      5                      0                      1
164907          4.357350                      6                      0                      0
164908          2.927453                      2                      0                      1
164909          3.744078                      5                      0                      0
164910          4.772970                      7                      0                      1
```

```
164911 rows × 12 columns
```

```
# Cuando se compiló el modelo con las variables seleccionadas, notamos que
# algunas no estaban incluidas, esto era a causa de la dependencia lineal que se
# formó entre algunas columnas, por tanto, verificamos cuáles estaban ocasionando
# el problema:
```

```
# Tipo_edificio_Edificiocompleto
# Estado_edificio_ProyectoNueva
# Estado_edificio_Obra_terminada
```

```
# Recorre cada columna y muestra los valores únicos
columnas = [
    .
    .
    .
```

```

'LogEmisiones',
'Clasificacion_Emisiones_ordinal',
'Tipo_edificio_Local',
'Tipo_edificio_Unifamiliar',
'Tipo_edificio_Edificiocompleto',
'coord_y',
'Tipo_edificio_Bloquecompleto',
'Estado_edificio_ProyectoNueva',
'Estado_edificio_ObraTerminada',
'Dias_hasta_expiracion',
'Anio_emision',
'Muy_antiguo'
]

```

```

for columna in columnas:
    print(f"Columna: {columna}")
    print(df_1[columna].unique())
    print("-"*50)

```

```

↗ Columna: LogEmisiones
[3.40485734 3.82994489 3.01062089 ... 5.21172408 5.01230057 4.77297015]
-----
Columna: Clasificacion_Emisiones_ordinal
[5 4 7 6 3 2 1]
-----
Columna: Tipo_edificio_Local
[0 1]
-----
Columna: Tipo_edificio_Unifamiliar
[0 1]
-----
Columna: Tipo_edificio_Edificiocompleto
[0]
-----
Columna: coord_y
[0.59547196 0.59559187 0.59291276 ... 0.34316301 0.35573486 0.69716777]
-----
Columna: Tipo_edificio_Bloquecompleto
[0 1]
-----
Columna: Estado_edificio_ProyectoNueva
[0]
-----
Columna: Estado_edificio_ObraTerminada
[0]
-----
Columna: Dias_hasta_expiracion
[3652 3653 3651 ... 4544 3003 4105]
-----
Columna: Anio_emision
[2013 2014 2015 2011 2012 2016 2017 2018 2019 2020 2021 2022 2023]
-----
Columna: Muy_antiguo
[0 1]
-----

```

#Entonces seleccionamos nuevamente las variables que explican el modelo.

```

df_2 = df_1[['LogEmisiones', 'Clasificacion_Emisiones_ordinal', 'Tipo_edificio_Local', 'Tipo_edificio_Unifamiliar',
             'coord_y', 'Tipo_edificio_Bloquecompleto', 'Dias_hasta_expiracion', 'Anio_emision', 'Muy_antiguo']]

```

df_2

	LogEmisiones	Clasificacion_Emisiones_ordinal	Tipo_edificio_Local	Tipo_edificio_Unifamiliar	coord_y	Tipo_edificio_Bloqu
0	3.404857	5	0	0	0.595472	
1	3.829945	5	0	0	0.595592	
2	3.010621	4	0	0	0.592913	
3	3.668932	5	0	0	0.596922	
4	4.641984	7	0	0	0.595892	
...
164906	4.038656	5	0	1	0.355735	
164907	4.357350	6	0	0	0.594765	
164908	2.927453	2	0	1	0.588639	
164909	3.744078	5	0	0	0.597117	
164910	4.772970	7	0	1	0.697168	

164911 rows × 9 columns

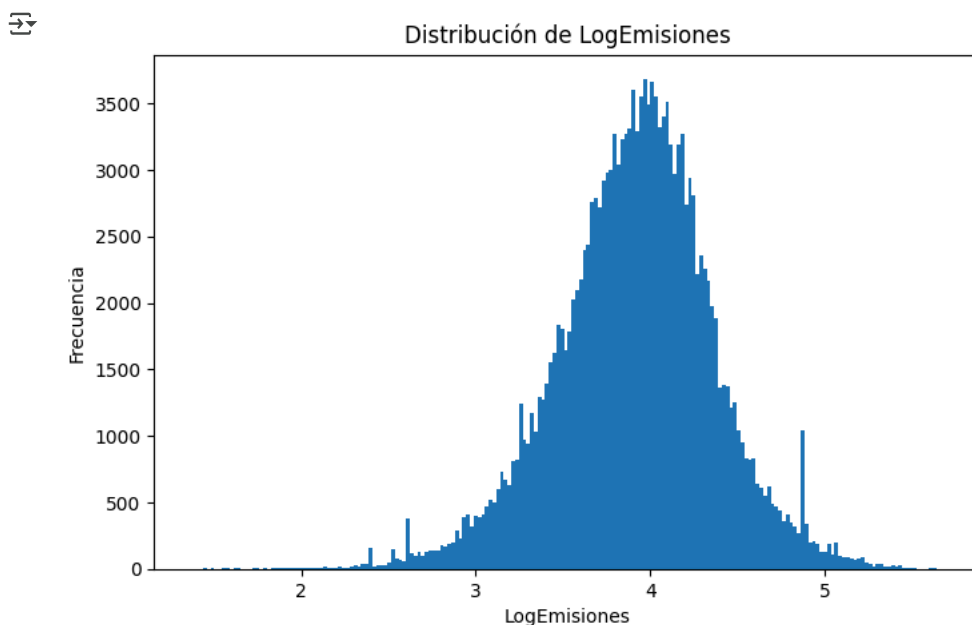
✓ Análisis gráfico

```
df_2.describe()
```

	LogEmisiones	Clasificacion_Emisiones_ordinal	Tipo_edificio_Local	Tipo_edificio_Unifamiliar	coord_y	Tipo_edificio_F
count	164911.000000	164911.000000	164911.000000	164911.000000	164911.000000	
mean	3.914228	5.063489	0.051252	0.136619	0.609406	
std	0.451535	0.964142	0.220512	0.343446	0.124285	
min	1.371181	1.000000	0.000000	0.000000	0.027387	
25%	3.646494	5.000000	0.000000	0.000000	0.591407	
50%	3.935935	5.000000	0.000000	0.000000	0.595856	
75%	4.197803	5.000000	0.000000	0.000000	0.604916	
max	5.683308	7.000000	1.000000	1.000000	0.996095	


```
import matplotlib.pyplot as plt
```

```
plt.figure(figsize=(8,5))
plt.hist(df_2["LogEmisiones"], bins=200)
plt.xlabel("LogEmisiones")
plt.ylabel("Frecuencia")
plt.title("Distribución de LogEmisiones")
plt.show()
```

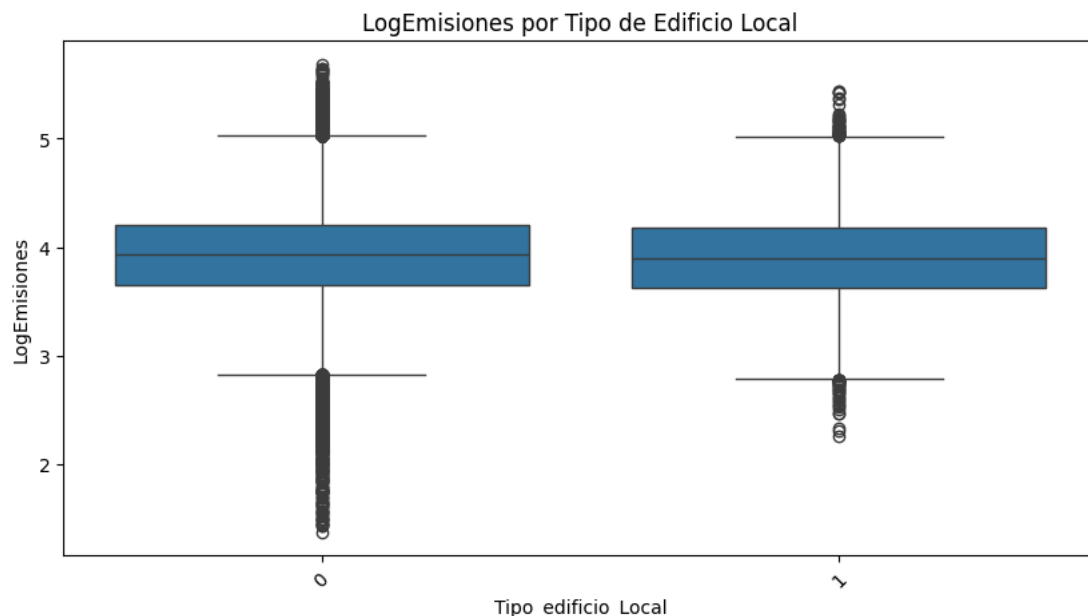


```
import seaborn as sns

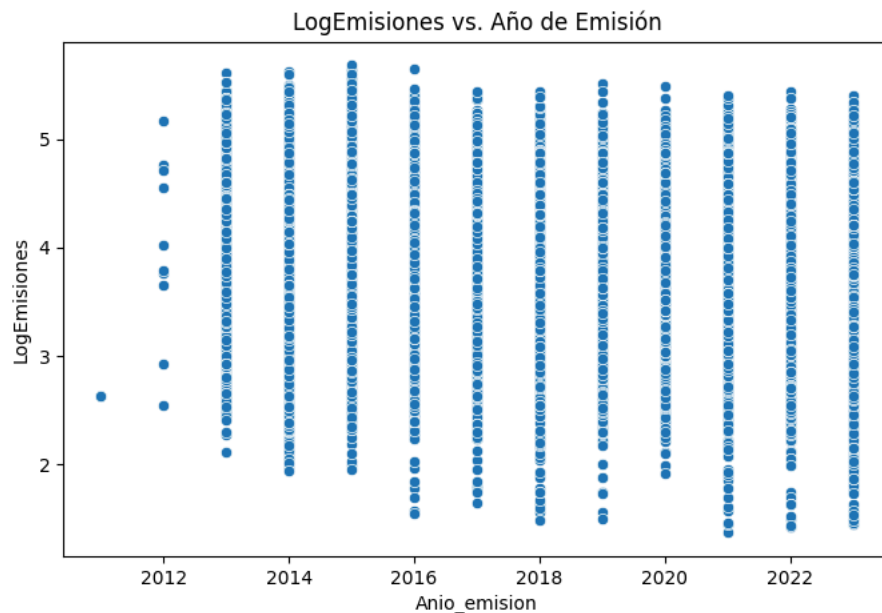
plt.figure(figsize=(8,5))
sns.boxplot(x="Clasificacion_Emissiones_ordinal", y="LogEmisiones", data=df_2)
plt.title("LogEmisiones según Clasificación Emisiones")
plt.show()
```



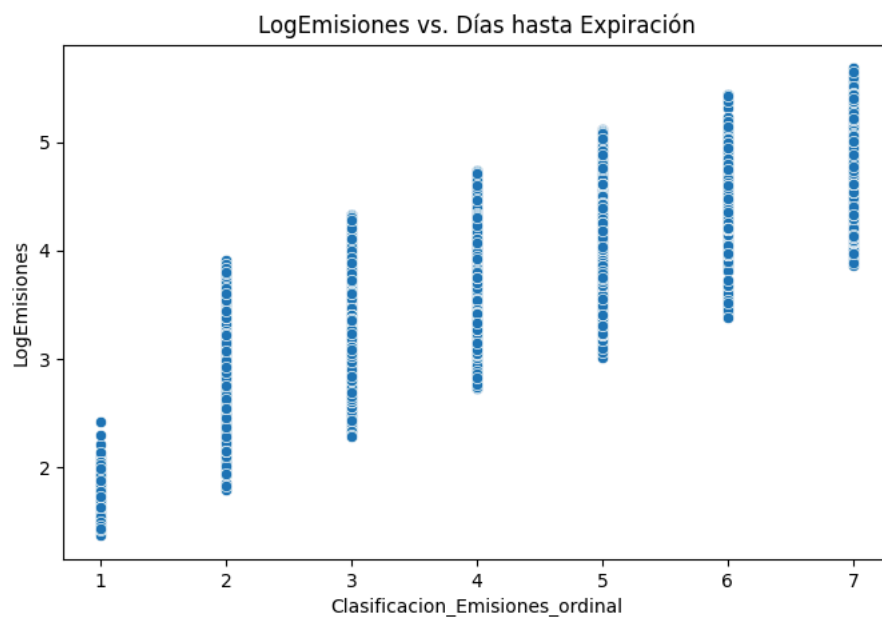
```
plt.figure(figsize=(10,5))
sns.boxplot(x="Tipo_edificio_Local", y="LogEmisiones", data=df_2)
plt.title("LogEmisiones por Tipo de Edificio Local")
plt.xticks(rotation=45)
plt.show()
```



```
plt.figure(figsize=(8,5))
sns.scatterplot(x="Año_emision", y="LogEmisiones", data=df_2)
plt.title("LogEmisiones vs. Año de Emisión")
plt.show()
```



```
plt.figure(figsize=(8,5))
sns.scatterplot(x="Clasificacion_Emisiones_ordinal", y="LogEmisiones", data=df_2)
plt.title("LogEmisiones vs. Días hasta Expiración")
plt.show()
```



Visualización de la clasificación de emisiones ordinal en la emisión de CO2 (Dummies)

```
print(df_2["Clasificacion_Emisiones_ordinal"].unique())
```



```
[5 4 7 6 3 2 1]
```

```
import pandas as pd
```

```
dummies = pd.get_dummies(
    df_2["Clasificacion_Emisiones_ordinal"],
    prefix="Clasif",
    drop_first=True,
    dtype=int # <-- Esto las hace int en lugar de bool
)
```

```
# Combinar dummies con df_2
```

```
df_3 = pd.concat([df_2, dummies], axis=1)
```

```
df_3.columns
```

```
Index(['LogEmisiones', 'Clasificacion_Emisiones_ordinal',
      'Tipo_edificio_Local', 'Tipo_edificio_Unifamiliar', 'coord_y',
      'Tipo_edificio_Bloquecompleto', 'Dias_hasta_expiracion', 'Anio_emision',
      'Muy_antiguo', 'Clasif_2', 'Clasif_3', 'Clasif_4', 'Clasif_5',
      'Clasif_6', 'Clasif_7'],
      dtype='object')
```

```
df_3
```

```

      LogEmisiones  Clasificacion_Emisiones_ordinal  Tipo_edificio_Local  Tipo_edificio_Unifamiliar  coord_y  Tipo_edificio_Bloqu
0      3.404857                5                0                0  0.595472
1      3.829945                5                0                0  0.595592
2      3.010621                4                0                0  0.592913
3      3.668932                5                0                0  0.596922
4      4.641984                7                0                0  0.595892
...      ...                ...                ...                ...      ...
164906  4.038656                5                0                1  0.355735
164907  4.357350                6                0                0  0.594765
164908  2.927453                2                0                1  0.588639
164909  3.744078                5                0                0  0.597117
164910  4.772970                7                0                1  0.697168

```

164911 rows × 16 columns

```
# regresión lineal múltiple
import statsmodels.api as sm
```

```
# Definir las variables independientes
```

```
X = df_3[
    [
        "Anio_emision",
        "Dias_hasta_expiracion",
        "coord_y",
        "Muy_antiguo",
        "Tipo_edificio_Local",
        "Tipo_edificio_Unifamiliar",
        "Tipo_edificio_Bloquecompleto",
        "Clasif_2",
        "Clasif_3",
        "Clasif_4",
        "Clasif_5",
        "Clasif_6",
        "Clasif_7"
    ]
]
```

```
# Agregar constante (intercepto)
X = sm.add_constant(X)
```

```
# Variable dependiente
y = df_3["LogEmisiones"]
```

```
# Ajustar el modelo
modelo = sm.OLS(y, X).fit()
```

```
# Mostrar resumen
print(modelo.summary())
```

```

      OLS Regression Results
=====
Dep. Variable:      LogEmisiones      R-squared:      0.776
Model:              OLS      Adj. R-squared:      0.776
Method:              Least Squares      F-statistic:      4.406e+04
Date:                Sun, 29 Jun 2025      Prob (F-statistic):      0.00

```

```

Time: 18:27:38 Log-Likelihood: 20662.
No. Observations: 164911 AIC: -4.130e+04
Df Residuals: 164897 BIC: -4.116e+04
Df Model: 13
Covariance Type: nonrobust

```

```

=====
              coef      std err          t      P>|t|      [0.025      0.975]
-----
const                -9.1896         0.359      -25.569      0.000      -9.894      -8.485
Anio_emision           0.0054         0.000       30.267      0.000         0.005         0.006
Dias_hasta_expiracion  6.275e-06      1.41e-06       4.450      0.000      3.51e-06      9.04e-06
coord_y               0.2373         0.004       55.953      0.000         0.229         0.246
Muy_antiguo           0.0216         0.002       10.794      0.000         0.018         0.025
Tipo_edificio_Local    0.5842         0.003      223.409      0.000         0.579         0.589
Tipo_edificio_Unifamiliar 0.2716         0.002      165.751      0.000         0.268         0.275
Tipo_edificio_Bloquecompleto 0.0477         0.002       30.649      0.000         0.045         0.051
Clasif_2              0.7024         0.022       31.512      0.000         0.659         0.746
Clasif_3              1.1807         0.022       54.328      0.000         1.138         1.223
Clasif_4              1.5343         0.022       70.956      0.000         1.492         1.577
Clasif_5              2.0639         0.022       95.625      0.000         2.022         2.106
Clasif_6              2.4640         0.022      113.882      0.000         2.422         2.506
Clasif_7              2.8184         0.022      130.130      0.000         2.776         2.861
=====
Omnibus: 1757.778 Durbin-Watson: 1.746
Prob(Omnibus): 0.000 Jarque-Bera (JB): 3048.548
Skew: 0.011 Prob(JB): 0.00
Kurtosis: 3.666 Cond. No. 2.83e+06
=====

```

Notes:

- [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
- [2] The condition number is large, 2.83e+06. This might indicate that there are strong multicollinearity or other numerical problems.


```
df_3["Predicciones"] = modelo.fittedvalues
```

```
import seaborn as sns
import matplotlib.pyplot as plt
```

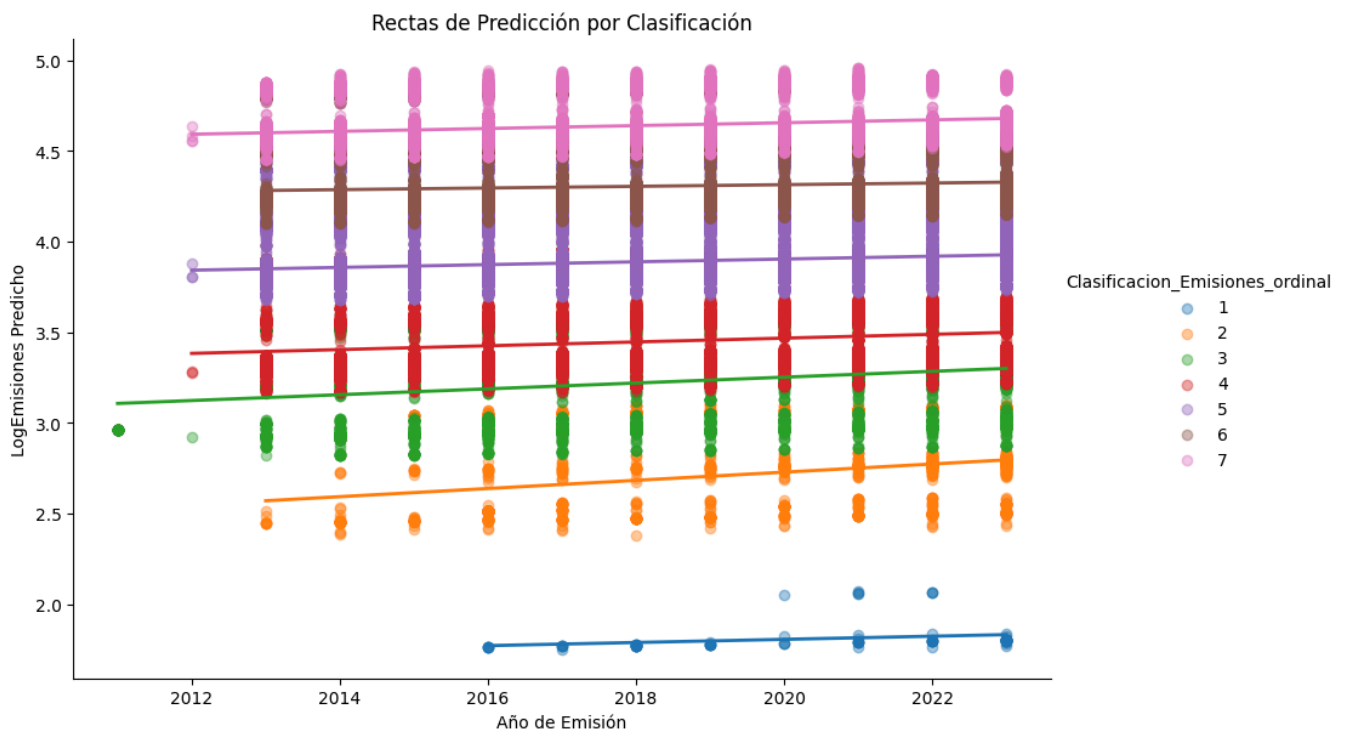
```

plt.figure(figsize=(10,6))
sns.scatterplot(
    data=df_3,
    x="Anio_emision",
    y="Predicciones",
    hue="Clasificacion_Emisiones_ordinal",
    palette="tab10",
    alpha=0.6
)
plt.title("Predicciones del Modelo por Clasificación")
plt.xlabel("Año de Emisión")
plt.ylabel("LogEmisiones Predicho")
plt.legend(title="Clasificación")
plt.show()

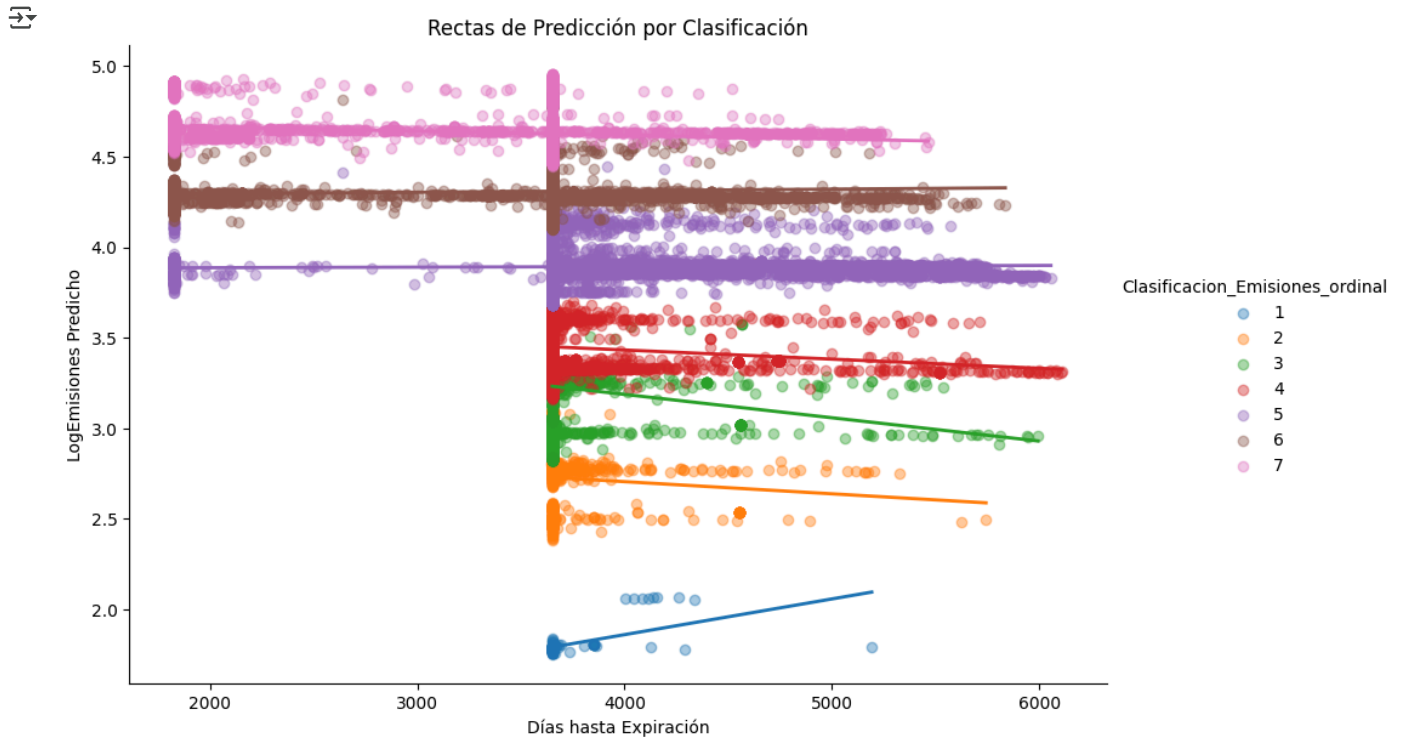
```



```
sns.lmplot(
    data=df_3,
    x="Año_emision",
    y="Predicciones",
    hue="Clasificacion_Emisiones_ordinal",
    height=6,
    aspect=1.5,
    ci=None,
    scatter_kws={"alpha":0.4},
    line_kws={"linewidth":2}
)
plt.title("Rectas de Predicción por Clasificación")
plt.xlabel("Año de Emisión")
plt.ylabel("LogEmisiones Predicho")
plt.show()
```





```
sns.lmplot(
    data=df_3,
    x="Dias_hasta_expiracion",
    y="Predicciones",
    hue="Clasificacion_Emisiones_ordinal",
    ci=None,
    height=6,
    aspect=1.5,
    scatter_kws={"alpha":0.4},
    line_kws={"linewidth":2}
)
plt.title("Rectas de Predicción por Clasificación")
plt.xlabel("Días hasta Expiración")
plt.ylabel("LogEmisiones Predicho")
plt.show()
```



```
sns.lmplot(
    data=df_3,
    x="Dias_hasta_expiracion",
    y="LogEmisiones",
    hue="Clasificacion_Emisiones_ordinal",
    ci=None,
    height=6,
    aspect=1.5,
    scatter_kws={"alpha":0.4},
    line_kws={"linewidth":2}
)
plt.title("Relación de Emisiones y Días hasta Expiración por Clasificación")
plt.xlabel("Días hasta Expiración")
plt.ylabel("LogEmisiones Observado")
plt.show()
```



Relación de Emisiones y Días hasta Expiración por Clasificación



✓ Scater plots de las dummies

```
import statsmodels.formula.api as smf
```

```
# Ajustar el modelo completo con TODAS las variables
```

```
modelo = smf.ols(
    "LogEmisiones ~ Clasificacion_Emisiones_ordinal + Anio_emision + Dias_hasta_expiracion + coord_y + Tipo_edificio_Local + Tipo_edificio_Nacional",
    data=df_2
).fit()
```

```
# Crear un dataframe con las predicciones
```

```
df_2["Predicciones"] = modelo.fittedvalues
```



C:\Users\JH0SSEP\AppData\Local\Temp\ipykernel_7912\2021751556.py:10: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
df_2["Predicciones"] = modelo.fittedvalues

```
df_2
```

	LogEmisiones	Clasificacion_Emisiones_ordinal	Tipo_edificio_Local	Tipo_edificio_Unifamiliar	coord_y	Tipo_edificio_Bloqu
0	3.404857	5	0	0	0.595472	
1	3.829945	5	0	0	0.595592	
2	3.010621	4	0	0	0.592913	
3	3.668932	5	0	0	0.596922	
4	4.641984	7	0	0	0.595892	
...
164906	4.038656	5	0	1	0.355735	
164907	4.357350	6	0	0	0.594765	
164908	2.927453	2	0	1	0.588639	
164909	3.744078	5	0	0	0.597117	
164910	4.772970	7	0	1	0.697168	

164911 rows × 9 columns

df_3

	LogEmisiones	Clasificacion_Emisiones_ordinal	Tipo_edificio_Local	Tipo_edificio_Unifamiliar	coord_y	Tipo_edificio_Bloqu
0	3.404857	5	0	0	0.595472	
1	3.829945	5	0	0	0.595592	
2	3.010621	4	0	0	0.592913	
3	3.668932	5	0	0	0.596922	
4	4.641984	7	0	0	0.595892	
...
164906	4.038656	5	0	1	0.355735	
164907	4.357350	6	0	0	0.594765	
164908	2.927453	2	0	1	0.588639	
164909	3.744078	5	0	0	0.597117	
164910	4.772970	7	0	1	0.697168	

164911 rows × 16 columns


```

import seaborn as sns
import matplotlib.pyplot as plt

# Graficar las predicciones coloreadas por tipo de edificio, con Días en X
sns.lmplot(
    data=df_3,
    x="Dias_hasta_expiracion",
    y="Predicciones",
    hue="Tipo_edificio_label",
    ci=None,
    height=6,
    aspect=1.5,
    scatter_kws={"alpha":0.4},
    line_kws={"linewidth":2}
)

plt.title("Predicciones de LogEmisiones por Tipo de Edificio")
plt.xlabel("Días hasta Expiración")
plt.ylabel("LogEmisiones Predicho")
plt.show()

```



df_3.columns

```
Index(['LogEmisiones', 'Clasificacion_Emissiones_ordinal',
      'Tipo_edificio_Local', 'Tipo_edificio_Unifamiliar', 'coord_y',
      'Tipo_edificio_Bloquecompleto', 'Dias_hasta_expiracion', 'Anio_emision',
      'Muy_antiguo', 'Clasif_2', 'Clasif_3', 'Clasif_4', 'Clasif_5',
      'Clasif_6', 'Clasif_7', 'Predicciones', 'Tipo_edificio_label'],
      dtype='object')
```

Empieza a programar o a [crear código](#) con IA.

✓ MODELO

```
import statsmodels.formula.api as smf
import matplotlib.pyplot as plt
import seaborn as sns

# Ajustar el modelo usando fórmula
formula = """
LogEmisiones ~ Anio_emision + Dias_hasta_expiracion + coord_y + Muy_antiguo +
                Tipo_edificio_Local + Tipo_edificio_Unifamiliar + Tipo_edificio_Bloquecompleto +
                Clasif_2 + Clasif_3 + Clasif_4 + Clasif_5 + Clasif_6 + Clasif_7
"""

modelo_f = smf.ols(formula=formula, data=df_3).fit()

# Mostrar resumen
print(modelo_f.summary())

# R-cuadrado
print("R-squared:", modelo_f.rsquared)

# Tabla ANOVA
from statsmodels.stats.anova import anova_lm
anova_table = anova_lm(modelo_f, typ=2)
print("\nANOVA Table:\n", anova_table)

# Gráfico residuos vs predicciones
plt.figure(figsize=(8,5))
sns.residplot(x=modelo_f.fittedvalues, y=modelo_f.resid, lowess=True, line_kws={"color":"red"})
plt.xlabel("Valores Predichos")
plt.ylabel("Residuos")
plt.title("Residuos vs Predicciones")
plt.axhline(0, color="gray", linestyle="--")
plt.show()
```




```

-----
Df Residuals:      164897    BIC:      -4.116e+04
Df Model:          13
Covariance Type:   nonrobust
=====
              coef      std err          t      P>|t|      [0.025      0.975]
-----
Intercept          -9.1896        0.359     -25.569      0.000      -9.894      -8.485
Anio_emision         0.0054        0.000      30.267      0.000        0.005        0.006
Dias_hasta_expiracion 6.275e-06      1.41e-06       4.450      0.000      3.51e-06      9.04e-06
coord_y             0.2373        0.004      55.953      0.000        0.229        0.246
Muy_antiguo         0.0216        0.002      10.794      0.000        0.018        0.025
Tipo_edificio_Local  0.5842        0.003      223.409      0.000        0.579        0.589
Tipo_edificio_Unifamiliar 0.2716        0.002      165.751      0.000        0.268        0.275
Tipo_edificio_Bloquecompleto 0.0477        0.002      30.649      0.000        0.045        0.051
Clasif_2            0.7024        0.022      31.512      0.000        0.659        0.746
Clasif_3            1.1807        0.022      54.328      0.000        1.138        1.223
Clasif_4            1.5343        0.022      70.956      0.000        1.492        1.577
Clasif_5            2.0639        0.022      95.625      0.000        2.022        2.106
Clasif_6            2.4640        0.022     113.882      0.000        2.422        2.506
Clasif_7            2.8184        0.022     130.130      0.000        2.776        2.861
=====
Omnibus:            1757.778    Durbin-Watson:      1.746
Prob(Omnibus):      0.000    Jarque-Bera (JB):    3048.548
Skew:               0.011    Prob(JB):            0.00
Kurtosis:           3.666    Cond. No.            2.83e+06
=====

```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 2.83e+06. This might indicate that there are strong multicollinearity or other numerical problems.

R-squared: 0.7764793657590837

ANOVA Table:

	sum_sq	df	F \
Anio_emision	41.752705	1.0	916.115158
Dias_hasta_expiracion	0.902648	1.0	19.805409
coord_y	142.687101	1.0	3130.762773
Muy_antiguo	5.309648	1.0	116.501402
Tipo_edificio_Local	2274.765294	1.0	49911.663153
Tipo_edificio_Unifamiliar	1252.126865	1.0	27473.486807
Tipo_edificio_Bloquecompleto	42.812372	1.0	939.365790
Clasif_2	45.258244	1.0	993.031770
Clasif_3	134.516675	1.0	2951.491730
Clasif_4	229.465684	1.0	5034.811272
Clasif_5	416.752978	1.0	9144.167239
Clasif_6	591.072737	1.0	12968.996581
Clasif_7	771.778290	1.0	16933.939579
Residual	7515.317042	164897.0	NaN

	PR(>F)
Anio_emision	1.097435e-200
Dias_hasta_expiracion	8.579576e-06
coord_y	0.000000e+00
Muy_antiguo	3.769213e-27
Tipo_edificio_Local	0.000000e+00
Tipo_edificio_Unifamiliar	0.000000e+00
Tipo_edificio_Bloquecompleto	1.033747e-205
Clasif_2	2.611621e-217
Clasif_3	0.000000e+00
Clasif_4	0.000000e+00
Clasif_5	0.000000e+00
Clasif_6	0.000000e+00
Clasif_7	0.000000e+00
Residual	NaN

KeyboardInterrupt Traceback (most recent call last)

Cell In[83], line 27

```

25 # Gráfico residuos vs predicciones
26 plt.figure(figsize=(8,5))
--> 27 sns.residplot(x=modelo_f.fittedvalues, y=modelo_f.resid, lowess=True, line_kws={"color":"red"})
28 plt.xlabel("Valores Predichos")
29 plt.ylabel("Residuos")

```

```

File c:\Users\JH0SSEP\anaconda3\envs\mi_entorno310\lib\site-packages\seaborn\regression.py:939, in residplot(data, x, y,
x_partial, y_partial, lowess, order, robust, dropna, label, color, scatter_kws, line_kws, ax)
    937 scatter_kws = {} if scatter_kws is None else scatter_kws.copy()
    938 line_kws = {} if line_kws is None else line_kws.copy()
--> 939 plotter.plot(ax, scatter_kws, line_kws)
    940 return ax

```

```

File c:\Users\JH0SSEP\anaconda3\envs\mi_entorno310\lib\site-packages\seaborn\regression.py:384, in _RegressionPlotter.plot(self,

```

```

ax, scatter_kws, line_kws)
381     self.scatterplot(ax, scatter_kws)
383 if self.fit_reg:
--> 384     self.lineplot(ax, line_kws)
386 # Label the axes
387 if hasattr(self.x, "name"):

```

```

File c:\Users\JHOSSEP\anaconda3\envs\mi_entorno310\lib\site-packages\seaborn\regression.py:429, in
_RegressionPlotter.lineplot(self, ax, kws)
427 """Draw the model."""
428 # Fit the regression model
--> 429 grid, yhat, err_bands = self.fit_regression(ax)
430 edges = grid[0], grid[-1]
432 # Get set default aesthetics

```

```

File c:\Users\JHOSSEP\anaconda3\envs\mi_entorno310\lib\site-packages\seaborn\regression.py:222, in
_RegressionPlotter.fit_regression(self, ax, x_range, grid)
220 elif self.lowess:
221     ci = None
--> 222     grid, yhat = self.fit_lowess()
223 elif self.robust:
224     from statsmodels.robust.robust_linear_model import RLM

```

```

File c:\Users\JHOSSEP\anaconda3\envs\mi_entorno310\lib\site-packages\seaborn\regression.py:309, in
_RegressionPlotter.fit_lowess(self)
307 """Fit a Locally-weighted regression, which returns its own grid."""
308 from statsmodels.nonparametric.smoothers_lowess import lowess
--> 309 grid, yhat = lowess(self.y, self.x).T
310 return grid, yhat

```

```

File c:\Users\JHOSSEP\anaconda3\envs\mi_entorno310\lib\site-packages\statsmodels\nonparametric\smoothers_lowess.py:226, in
lowess(endog, exog, frac, it, delta, xvals, is_sorted, missing, return_sorted)
223 x = np.ascontiguousarray(x)
224 if not given_xvals:
225     # Run LOWESS on the data points
--> 226     res, _ = _lowess(y, x, x, np.ones_like(x),
227                     frac=frac, it=it, delta=delta, given_xvals=False)
228 else:
229     # First run LOWESS on the data points to get the weights of the data points
230     # using it-1 iterations, last iter done next
231     if it > 0:

```

```

File statsmodels/nonparametric/_smoothers_lowess.pyx:201, in statsmodels.nonparametric._smoothers_lowess.lowess()

```

```

File statsmodels/nonparametric/_smoothers_lowess.pyx:346, in statsmodels.nonparametric._smoothers_lowess.calculate_weights()

```

```

File c:\Users\JHOSSEP\anaconda3\envs\mi_entorno310\lib\site-packages\numpy\_core\fromnumeric.py:2333, in _sum_dispatcher(a,
axis, dtype, out, keepdims, initial, where)
2327     raise ValueError("Passing `min` or `max` keyword argument when "
2328                     "`a_min` and `a_max` are provided is forbidden.")
2330     return _wrapfunc(a, 'clip', a_min, a_max, out=out, **kwargs)
--> 2333 def _sum_dispatcher(a, axis=None, dtype=None, out=None, keepdims=None,
2334                     initial=None, where=None):
2335     return (a, out)
2338 @array_function_dispatch(_sum_dispatcher)
2339 def sum(a, axis=None, dtype=None, out=None, keepdims=np._NoValue,
2340        initial=np._NoValue, where=np._NoValue):

```

KeyboardInterrupt:

